



STATISTIQUE
SCIENCE DES DONNÉES MIND
UNIVERSITÉ DE MONTPELLIER

ANALYSE MULTIVARIÉE

TP1: Régressions régularisées

Présenté par :

Abdoulaye Diop

Kenewy Diallo

Sous la direction de :

Professeur Xavier Bry

2024-11-04

Contents

1. Base de données
2. Première régression sur composantes principales
 - 2.1 ACP Globale
 - a) Choix du nombre d'axes à retenir
 - Plan principal direct (1,2)
 - Plan principal dual (1,2)
 - Plan principal direct/dual
 - 2.2 Modélisation de la densité à partir des composantes retenues
 - 2.3 Les coefficients des variables originelles
 - 2.4 Correction de la linéarité
3. Seconde régression sur composantes principales
 - 3.1 ACP par thème
 - Thème Photosynthèse
 - Thème Géographie
 - 3.2 Modélisation de la densité à partir des composantes issues d'ACP séparées des thèmes
 - 3.3 Coefficients originels
 - 3.4 Correction de la linéarité de la liaison en utilisant une transformation de type Log sur la densité
4. Régression PLS
 - 4.1 Modélisation de la densité par PLS
 - 4.2 Comparaison de l'ajustement du modèle obtenu avec ceux des régressions sur composantes principales
5. Régressions pénalisées
 - 5.1 Régression RIDGE
 - 5.2 Régression LASSO
6. Synthèse & conclusions

Introduction

L'objectif de ce TP est de modéliser la densité globale du peuplement arboré en utilisant les autres variables disponibles dans le jeu de données. Pour atteindre cet objectif, nous explorerons plusieurs techniques de modélisation, dont les performances seront comparées pour identifier celle offrant les meilleurs résultats.

Nous disposons d'un jeu de données, disponible dans le fichier `genus.csv`, qui porte sur l'abondance de 27 espèces d'arbres dans le bassin du Congo.

Ce jeu de données contient :

- Les niveaux d'abondance pour chaque espèce d'arbres (de `gen1` à `gen27`),
- Des variables géographiques quantitatives, telles que la latitude, la longitude, l'altitude, ainsi que les pluviométries annuelles et mensuelles,
- Une variables géographique qualitative, décrivant le type de sol,
- Des variables relatives à la photosynthèse, représentées par les indices EVI.

Toutes ces informations sont collectées à partir de parcelles forestières, dont la surface est indiquée dans la dernière colonne du fichier.

1) Calculs de variables


1.1) Calcul de la variable dépendante Y

La densité de peuplement arboré est un paramètre crucial pour comprendre la dynamique des forêts et leur rôle dans les écosystèmes. Dans les écosystèmes forestiers, la densité influence non seulement la croissance et la productivité des arbres, mais aussi la biodiversité, la compétition pour les ressources, et les interactions entre les espèces. Modéliser cette densité est essentiel pour la gestion durable des forêts, particulièrement dans des régions comme le bassin du fleuve Congo, où une diversité remarquable d'espèces coexiste dans des conditions environnementales variées. La variable Y est la densité global du peuplement est obtenue en faisant la somme des abondances des 27 espèces divisée par la surface de chaque parcelle :

$$Y_i = \frac{\sum_{j=1}^{27} (\text{Gen}_j)_i}{\text{Surface}_i}$$


1.2) Calcul du tableau des variables explicatives

Nous allons d'abord établir le tableau des indicatrices pour la variable *géologie*. Cette variable est qualitative et comprend cinq modalités représentant différents types de sol. La figure ci-dessous illustre la distribution de la densité en fonction de chacune des modalités de la variable *géologie*.



On peut remarquer une différence significative entre les densités, ce qui indique que la variable *géologie* influence la modélisation de Y . Cela nous conduit à calculer les interactions entre la variable *géologie* et le tableau des variables géographiques. Pour modéliser la densité du peuplement Y , nous avons besoin des variables explicatives, qui incluent les variables quantitatives et qualitatives liées au thème géographique, ainsi que le produit des interactions entre les variables quantitatives et la *géologie* et enfin les variables de photosynthèse.

Faisons à présent l'inventaire des multicollinéarités présentes dans l'ensemble des variables explicatives :



Ce graphique est une matrice de corrélation montrant les relations entre les différentes variables

explicatives.

On peut observer les points suivants :


- La pluviométrie de janvier et février est fortement corrélée positivement avec celle de novembre et décembre, et fortement corrélée négativement avec la pluviométrie de juin, août et septembre.
- Les interactions entre les variables au sein de la même modalité montrent également des corrélations positives. Par exemple, *altitude_Sol1* est positivement corrélée avec *pluvio_1_Sol1*.
- Les variables liées au thème de la photosynthèse sont également corrélées positivement entre elles. En particulier, on observe une forte corrélation entre *Evi1* et *Evi5*.

2. Première régression sur composantes principales

2.1 ACP Globale

a) Choix du nombre d'axes à retenir

Les valeurs propres mesurent la quantité de variances expliquée par chaque axe principal. On affichera les valeurs propres et on les examinera pour déterminer le nombre de composantes principales à prendre en considération :



	Valeurs propres	Inertie	Inertie (% cumul)
Dim.1	29.2501	23.5888	23.5888
Dim.2	23.7728	19.1716	42.7604
Dim.3	21.8904	17.6536	60.4139
Dim.4	18.6521	15.0420	75.4560
Dim.5	10.3074	8.3121	83.7681
Dim.6	6.4087	5.1683	88.9364
Dim.7	2.7102	2.1856	91.1221
Dim.8	1.2771	1.0293	92.1520
Dim.9	0.9294	0.7495	92.9015
Dim.10	0.9067	0.7312	93.6327

Table 1: Description des dimensions


La somme de toutes les valeurs propres est égale à 124, ce qui correspond au nombre de variables (seules les 10 premières composantes sont affichées ici).

Une inertie supérieure à 0,8065% ($\frac{100}{124}$) indique que la composante principale concernée représente plus de variance qu'une seule variable d'origine. On peut également observer la valeur propre et considérer l'axe comme du bruit si celle-ci est inférieure à 1.

En partant du principe qu'une composante est du bruit si elle explique moins de variance qu'une variable d'origine, nous avons décidé de retenir les 8 premières composantes principales pour notre analyse. En effet, à partir de la 9^{ème} composante, chacune capture moins de variance qu'une seule variable.


Ainsi, le sous-espace formé par les 8 premières composantes principales capture 92,21% de la variance totale, un résultat très satisfaisant.

Dans la suite, nous allons examiner brièvement le premier plan principal (dual et direct) sans nécessairement les interpréter en détail, car ces composantes principales sont principalement utilisées ici dans le cadre de la régression sur les composantes principales (RCP).




Avant tout, on observe immédiatement des groupes d'individus bien distincts. En examinant le deuxième plan principal (1,2), on constate que les parcelles forestières se regroupent en fonction de la variable *geology* (type de sol).

Le graphique de gauche montre que les parcelles forestières de types de sol 1, 5 et 6 sont les plus contributives sur le plan (1,2), ce qui suggère que ce plan oppose principalement ces trois types de sol. Pour comprendre les raisons de la position de ces groupes d'individus, nous allons examiner le plan dual (1,2).



La première figure, située à gauche, montre une ACP duale de toutes les variables. Certaines variables y sont mal représentées, ce qui rend l'analyse difficile. En revanche, dans la figure de droite, seules les variables bien représentées (celles dont le cosinus dépasse 0,7) sont affichées. On observe trois groupes correspondant aux interactions avec les types de sol : *sol3*, *sol5* et *sol6*. Une forte corrélation positive est visible entre les interactions des variables d'un même type de sol, ce qui est attendu étant donné l'introduction de variables d'interaction. Cependant, ces corrélations, bien qu'elles reflètent des relations internes, n'apportent pas d'informations pertinentes et compliquent l'analyse exploratoire.

Plan ACP Direct et Dual (1,2) avec Filtre $\text{Cos}^2 \geq 0,6$



Sur ce plan, on observe que les parcelles forestières de type de sol 1 se distinguent par une pluviométrie très élevée en janvier et par une faible pluviométrie en été (juin, juillet, août et septembre).

2.2) Modélisation de la densité à partir des composantes retenues

Le modèle peut s'écrire comme: $Y = C\theta + \epsilon_i$, avec C la matrice des composantes retenues et θ les coefficients de la régression.

La régression sur composantes principales (RCP) permet de remplacer les variables initiales par des composantes principales qui conservent la quasi-totalité de l'information et présentent l'avantage d'être non corrélées. Ces composantes principales sont ensuite utilisées comme variables explicatives dans une régression linéaire multiple.

Nous allons régresser la variable densité sur les 8 premières composantes que nous avons retenues. On obtient un $R^2 = 0.2127$, ce qui signifie que 21,27 % de la variation dans la densité peut être expliquée par l'ensemble de ces composantes principales, un pourcentage relativement faible.

En examinant la Table 2, on remarque que les deux dernières composantes principales (7 et 8) n'ont pas de rôle statistiquement significatif, car leur p-value est supérieure à 5 %.

Il est donc justifié d'envisager l'élimination des deux dernières composantes pour simplifier le modèle sans perte significative d'information.

	Coefficients estimés	Pr(> t)
Intercept	17.62022	$< 2 \times 10^{-16}$
Dim.1	0.28074	1.06×10^{-10}
Dim.2	0.30555	2.31×10^{-10}
Dim.3	-0.19368	0.000104
Dim.4	0.14589	0.006862
Dim.5	-0.25682	0.000411
Dim.6	1.11101	$< 2 \times 10^{-16}$
Dim.7	-0.13299	0.346770
Dim.8	0.28420	0.167609


Table 2: RCP sur les 8 composantes retenues

Maintenant nous allons faire la régression sur les 6 composantes significatives


	Coefficients estimés	Pr(> t)
Intercept	17.62022	$< 2 \times 10^{-16}$
Dim.1	0.28074	1.06×10^{-10}
Dim.2	0.30555	2.31×10^{-10}
Dim.3	-0.19368	0.000104
Dim.4	0.14589	0.006862
Dim.5	-0.25682	0.000411
Dim.6	1.11101	$< 2 \times 10^{-16}$

Table 3: Résumé RCP sur les 6 composantes

On obtient un $R^2 = 0.2105$, sensiblement égal au modèle RCP avec 8 composantes. Par le principe de parcimonie, on choisit le modèle le plus simple, c'est-à-dire le RCP avec 6 composantes. Nous allons vérifier maintenant si le test de Student est valide en examinant la normalité des résidus.



D'après le graphique, les données ne suivent une distribution normale car les points ne sont pas alignés sur une ligne droite. L'hypothèse de normalité n'est donc pas vérifiée.



On observe, dans le nuage de points du modèle d'identité, que la densité mesurée est systématiquement plus élevée que celle prédite. Cette observation suggère qu'une hypothèse du modèle linéaire n'est pas respectée : l'hypothèse de linéarité.

En effet, en se référant à la première bissectrice, on remarque que, plus la densité observée est grande, plus les erreurs sont négatives ; à l'inverse, pour des valeurs faibles, les erreurs sont positives. Autrement dit, la prédiction présente un biais : elle est positivement biaisée pour les petites valeurs et négativement biaisée pour les grandes valeurs.

2.2) Les coefficients des variables originelles

Les coefficients des variables originelles dans le prédicteur linéaire sont :

$$\begin{aligned}\hat{Y} &= C\hat{\beta} + \hat{\beta}_{011} = Zu\hat{\beta} + \hat{\beta}_{011} = [X - \mathbf{1}\mathbf{1}'WX]S^{-1/2}u\hat{\beta} + \hat{\beta}_{011} \\ &= XS^{-1/2}u\hat{\beta} - \mathbf{1}\mathbf{1}'WXS^{-1/2}u\hat{\beta} + \hat{\beta}_{011} = X\hat{\gamma} + \hat{\gamma}_{011}\end{aligned}$$

Avec :

$$\hat{\gamma} = S^{-1/2}u\hat{\beta} \quad \text{et} \quad \hat{\gamma}_0 = -\mathbf{1}(\mathbf{1}'WX)S^{-1/2}u\hat{\beta} + \hat{\beta}_{011}$$

- $W = \text{diag}(1/n, i = 1, \dots, n)$.
- $\mathbf{1} \in \mathbb{R}^n$: est le vecteur unitaire.
- $S = \text{diag}(\sigma_j^2, j = 1, \dots, p)$: où σ_j^2 est la variance de la variable j .

2.4) Correction de la linéarité


$$\log(Y + 1) = C\theta + \epsilon_i$$

Avec C la matrice des composantes que nous avons retenues et θ les coefficients de la régression.

	Coefficients estimés	$\Pr(> t)$
Intercept	2.821583	$< 2 \times 10^{-16}$
Dim.1	0.016452	1.21×10^{-11}
Dim.2	0.018424	7.79×10^{-12}
Dim.3	-0.013529	1.24×10^{-6}
Dim.4	0.009816	0.00112
Dim.5	-0.028612	2.69×10^{-12}
Dim.6	0.068774	$< 2 \times 10^{-16}$

Table 4: Résumé de la régression linéaire multiple entre $\log(Y + 1)$ et les 6 CP de X

On obtient un $R^2 = 0.2657$, ce qui signifie que 26.54% de la variabilité de $\log(Y + 1)$ peut être expliquée par les 6 composantes principales de X. Comparé au premier modèle où l'on avait un $R^2 = 0.2105$, on observe une amélioration dans l'explication de la variance.



On a donc tenté de corriger la linéarité de la liaison en utilisant une transformation de type Log sur la densité. Globalement il n'y a pas une très grande amélioration mais le modèle logarithmique est quand même légèrement meilleur en termes d'ajustement

	R^2	$R^2_{ajusté}$
Le modèle identité	0.2105	0.2057
Le modèle Log	0.2657	0.2612

Table 5: Comparaison des modèles avec R^2 et $R^2_{ajusté}$

3. Seconde régression sur composantes principales

Dans cette section, nous allons effectuer une Analyse en Composantes Principales (ACP) sur les deux thèmes suivants :

- Le thème **Photosynthèse**, qui contient les variables associées aux indices EVI.

- Le thème **Géographie**, qui contient le reste des variables.

Ensuite, nous allons reprendre ce que nous avons fait dans la section précédente en combinant les composantes principales issues de chaque ACP afin de mieux modéliser Y.

3.1 ACP par thème


3.1.a ACP sur le thème photosynthèse

Ce thème **Photosynthèse** regroupe les 23 variables de l'indice de végétation amélioré.

	Valeurs propres	Inertie	Inertie (% cumul)
Dim.1	11.2615	48.9630	48.9630
Dim.2	3.9947	17.3682	66.3312
Dim.3	1.6703	7.2620	73.5932
Dim.4	0.8396	3.6504	77.2436
Dim.5	0.6221	2.7047	79.9483
Dim.6	0.5339	2.3214	82.2697
Dim.7	0.4475	1.9458	84.2155
Dim.8	0.3857	1.6771	85.8926
Dim.9	0.3653	1.5881	87.4807
Dim.10	0.3520	1.5304	89.0115

Table 6: Pourcentage d'inertie apporté par chaque dimension

Tout d'abord, nous disposons de 23 variables de photosynthèse. En considérant les composantes principales ayant un pourcentage d'inertie inférieur à $\frac{100}{23} = 4.348\%$ comme du bruit, nous retiendrons donc les trois premières composantes qui captent 73.59% de l'inertie totale, soit presque trois quarts.




Examinons maintenant le premier plan factoriel dual et le heatmap. Ce plan met en évidence les variables bien représentées. En termes de corrélations, on observe que toutes les corrélations sont positives. De plus, les variables evi_4, evi_2 et evi_22 sont fortement corrélées, tout comme les variables evi_12 et evi_11.

3.1.b ACP sur le thème Géographie

De manière analogue, nous allons effectuer l'Analyse en Composantes Principales (ACP) du thème *géographie* qui contient les variables restantes (101 variables).

Nous allons afficher le tableau des valeurs propres en utilisant la commande `pca_geo$eig`.




	Valeurs propres	Inertie (%)	Inertie (% cumul)
comp 1	28.0586598	27.7808513	27.78085
comp 2	23.2423623	23.0122399	50.79309
comp 3	20.0104218	19.8122988	70.60539
comp 4	18.4394620	18.2568931	88.86228
comp 5	5.3139784	5.2613647	94.12365
comp 6	1.6574445	1.6410342	95.76468
comp 7	0.8243009	0.8161395	96.58082
comp 8	0.6762084	0.6695132	97.25033
comp 9	0.6023489	0.5963851	97.84672
comp 10	0.4328730	0.4285871	98.27531

Table 7: Description des dimensions

À première vue, on a envie de prendre ici les 4 premières composantes car on observe un décrochement important de l'inertie. Cependant, en termes de bruit, les composantes qui captent moins de 0,9901% ($\frac{100}{101}$) de la variance sont considérées comme du bruit. C'est pourquoi on retiendra plutôt les 6 premières composantes, qui engendrent un sous-espace capturant 95,793% de la variance totale.

Nous allons examiner la projection sur le plan dual



On a affiché uniquement les variables bien représentées, c'est-à-dire celles dont le cosinus est supérieur à 0,7.
 En termes de corrélations, on peut également remarquer que les interactions entre les variables géographiques et la modalité sol_5 sont fortement corrélées.

3.2 Modélisation de la densité à partir des composantes issues d'ACP séparées des thèmes

Dans cette section, nous allons modéliser la densité Y en utilisant les composantes principales issues des deux ACP effectuées séparément.

Pour cela, nous avons d'abord réalisé une ACP sur le thème *Photosynthèse*, puis une autre sur le thème *Géographie*, en extrayant respectivement les trois premières et les six premières composantes principales, ont ensuite été utilisées pour construire un modèle de régression linéaire multiple ayant Y comme variable de réponse.

	Coefficients estimés	Pr(> t)
Intercept	17.620225	$< 2 \times 10^{-16}$
geo_dim1	0.207981	1.54×10^{-3}
geo_dim2	-0.298551	4.16×10^{-9}
geo_dim3	-0.112299	4.405×10^{-2}
geo_dim4	0.093756	0.09798
geo_dim5	-0.899434	4.72×10^{-11}
geo_dim6	-0.272416	0.21088
evi_dim1	0.000291	0.99738
evi_dim2	-0.699608	5.44×10^{-6}
evi_dim3	0.010834	0.96905

Table 8: RCP sur l'union

On obtient un $R^2 = 0.2073$, ce qui signifie que 20,73% de la variation dans la densité peut être expliquée par l'ensemble de ces 9 composantes principales. Ce pourcentage reste relativement faible et inférieur à celui du premier modèle, pour lequel $R^2 = 0.2127$.

En examinant la Table 8, nous observons que les p-valeurs associées aux composantes `geo_dim4`, `geo_dim6`, `evi_dim1` et `evi_dim3` sont toutes supérieures à 0,05, indiquant qu'elles ne sont pas statistiquement significatives.


Maintenant nous allons faire la régression sur les composantes significatives

	Coefficients estimés	$\Pr(> t)$
(Intercept)	17.62022	$< 2 \times 10^{-16}$
<code>evi_dim2</code>	-0.79958	4.49×10^{-9}
<code>geo_dim1</code>	0.20080	1.21×10^{-5}
<code>geo_dim2</code>	-0.29552	1.67×10^{-9}
<code>geo_dim3</code>	-0.10817	0.0395
<code>geo_dim5</code>	-0.86321	5.95×10^{-14}

Table 9: Coefficients estimés et significativité statistique

On obtient un R^2 de 20,35%. Par le principe de parcimonie, on choisit le modèle le plus simple, c'est-à-dire celui avec les 5 composantes.

Pour évaluer les performances de notre modèle, nous allons tracer le graphique des valeurs observées Y en fonction des valeurs prédites $\hat{Y}$.



En observant le graphique, on constate que le nuage de points ne se rapproche toujours pas de la droite $y = x$. Cela signifie que les données réelles (valeurs observées) ne sont pas très bien estimées par notre modèle.

	Coefficients estimés	$\Pr(> t)$
(Intercept)	2.821583	$< 2 \times 10^{-16}$
<code>composantes_P1</code>	-0.036201	1.96×10^{-6}
<code>Dim.1</code>	0.012196	2.10×10^{-6}
<code>Dim.2</code>	-0.018765	9.15×10^{-12}
<code>Dim.3</code>	-0.006612	0.0246
<code>Dim.5</code>	-0.070009	$< 2 \times 10^{-16}$

Table 10: Coefficients estimés et significativité statistique

3.3 Coefficients originels

On note :

- X_{geo} le tableau des variables du thème géographie.
- X_{evi} le tableau des variables associées aux indices EVI.
- $C^{\text{geo}} = [c_1^{\text{geo}}, \dots, c_6^{\text{geo}}]$ le vecteur des 6 composantes principales de l'ACP de X_{geo} .
- $C^{\text{evi}} = [c_1^{\text{evi}}, \dots, c_3^{\text{evi}}]$ les composantes principales du tableau de l'ACP de X_{evi} .
- $U_{\text{geo}}, U_{\text{evi}}$ la matrice des vecteurs propres de l'ACP de $X_{\text{geo}}, X_{\text{evi}}$ respectivement.

On a :

$$\hat{Y} = [C^{\text{geo}}, C^{\text{evi}}]\beta$$

$$\text{Or, } C^{\text{geo}} = X_{\text{geo}}U_{\text{geo}} \text{ et } C^{\text{evi}} = X_{\text{evi}}U_{\text{evi}}$$

On obtient alors :

$$\hat{Y} = [X_{\text{geo}}U_{\text{geo}}, X_{\text{evi}}U_{\text{evi}}]\beta = [X_{\text{geo}}U_{\text{geo}}\beta_{\text{geo}}, X_{\text{evi}}U_{\text{evi}}\beta_{\text{evi}}]$$


3.4 Correction de la linéarité de la liaison en utilisant une transformation de type Log sur la densité

Pour ajuster la linéarité, nous allons effectuer la régression de $\log(y + 1)$ sur les composantes significatives.

Bien que la transformation logarithmique ne corrige pas totalement la non-linéarité, elle améliore néanmoins le modèle.

On obtient un R^2 de 0,2543, ce qui signifie que 25,43% de la variabilité de $\log(Y + 1)$ peut être expliquée par les 6 composantes principales de X . Comparé au modèle RCP sur les 5 composantes par thème, où l'on avait un $R^2 = 0,2035$, on observe une amélioration dans l'explication de la variance.

Graphique des Valeurs Observées vs Prédites avec l'union du modèle log



	R^2	$R^2_{ajusté}$
Le modèle identité	0.2035	0.1995
Le modèle Log	0.2543	0.2506


Table 11: Comparaison des modèles en termes de R^2 et $R^2_{ajusté}$

En prenant les composantes issues de l'ACP des thèmes séparés puis faire la régression donne le même résultat qu'en prenant les composantes issues de l'ACP de thèmes regroupés. Le nuage de points est quasiment le même.


4. Régression PLS

La régression PLS (Partial Least Squares) est une technique de régularisation qui repose sur la réduction de la dimensionnalité des prédicteurs. Nous allons maintenant appliquer cette méthode à notre jeu de données afin de modéliser précisément la densité. Étant donné la non-linéarité du modèle initial, nous utiliserons la variable $\log(Y + 1)$ comme variable dépendante. Cette transformation permet d'améliorer la qualité de notre analyse, comme l'indiquent les parties précédentes qui montrent que le modèle logarithmique améliore les performances du modèle.

Le choix du nombre de composantes est crucial lors de la réalisation d'une régression PLS, car un nombre trop élevé de composantes peut introduire du bruit, tandis qu'un nombre trop faible peut entraîner la perte d'informations importantes. Pour cela, nous allons effectuer une validation croisée afin de déterminer le nombre optimal de composantes à utiliser.




D'après le figure ci-dessus, il semble que le nombre optimal de composantes soit de 22. Pour confirmer cette première estimation, nous allons tracer le MSEP (Mean Square Error of Prediction) en fonction du nombre de composantes sélectionnées.



Le MSEP atteint son minimum, pour un nombre de composantes égal à 22, confirmant ainsi notre première estimation. Nous retiendrons donc 22 composantes pour la suite de l'analyse. Nous allons maintenant effectuer notre régression PLS en utilisant ce nombre de composantes.

4.1 Modélisation de la densité par PLS

On s'intéresse de la régression de $\log(\text{densité} + 1)$ sur les 22 composantes PLS, et nous obtenons un R^2 de 0,4594.



	R^2	R^2 ajusté
Modèle PLS 22 comp	0.4594	0.4473
Modèle PCR 6 comp	0.2543	0.2506

Table 12: Comparaison des modèles PLS et PCR en termes de R^2 et R^2 ajusté

On remarque que la régression sur les composantes PLS a un R^2 de 45%, ce qui signifie qu'environ la moitié de la variance de Y est expliquée par le modèle. En revanche, pour la régression par composantes principales (RCP), nous avons un R^2 de seulement 20%. Cela indique que la régression PLS explique mieux la variance de Y que la RCP.

Ce résultat s'explique par le fait que la RCP ne rend pas compte de la structure de Y lors de la construction de ses composantes. En revanche, les composantes PLS maximisent la covariance entre X et Y , ce qui leur permet de mieux représenter la variabilité de Y dans le modèle. Ainsi, la régression PLS se révèle plus efficace pour modéliser la relation entre les variables.

Nous avons fait le choix de sélectionner seulement les corrélations supérieures à 0.7 en valeur absolue afin de ne sélectionner que les variables présentant une forte corrélation avec la variable density

Variables explicatives	Corrélation
pluvio_1	-0.7673
pluvio_2	-0.7886
pluvio_6	0.7678
pluvio_7	0.7127
pluvio_8	0.8408
pluvio_11	-0.7700
pluvio_12	-0.7519
lat	0.7802
altitude_Sol3	0.7331
pluvio_yr_Sol3	0.7115
pluvio_5_Sol3	0.7049
pluvio_6_Sol3	0.7540
pluvio_7_Sol3	0.7749
pluvio_8_Sol3	0.7767
pluvio_9_Sol3	0.7299
pluvio_10_Sol3	0.7098
lon_Sol3	0.7219
lat_Sol3	0.7876
Sol3	0.7102

Table 13: Extrait corrélations composante 1

Les variables en lien avec la pluviométrie sont prédominantes dans l'analyse des corrélations sur ces deux premières composantes.

Variables explicatives	Corrélation
pluvio_4	-0.7764
pluvio_7	0.7959
pluvio_8	0.8488
pluvio_11	-0.8661
lat	0.7007

Table 14: Extrait corrélations composantes 2

5. Régressions pénalisées

Dans cette partie, nous utiliserons les deux méthodes de régularisation des modèles, à savoir Ridge et LASSO, qui ont pour objectif commun de trouver un bon estimateur biaisé de faible variance, afin que le modèle considéré puisse avoir un bon pouvoir prédictif. Comme dans la partie sur les régressions sur composantes, où nous avons constaté que la densité est mieux estimée avec $\log(\text{density} + 1)$, nous allons utiliser cette transformation pour effectuer les régressions Ridge et LASSO.

5.1 Régression RIDGE


L'une des méthodes de régularisation consiste à minimiser l'erreur quadratique moyenne $\sum_{i=1}^n (y_i - x_i \beta)^2$ (OLS) sous la contrainte $\sum_{j=1}^p \beta_j^2 \leq \gamma$. Cela revient à minimiser $\sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2$ pour un certain λ dépendant de γ , où λ est appelé le multiplicateur de Lagrange. L'estimateur ridge est alors défini par :

$$\hat{\beta}^R \in \arg \min \left(\sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right)$$

Ce qui donne :


$$\hat{\beta}^R = (X^T X + \lambda I_p)^{-1} X^T y$$

Pour trouver le paramètre de régularisation optimal, nous avons effectué une méthode de validation croisée à 10 ensembles. Nous avons constaté que celui-ci devait se situer dans une plage entre 0 et 0.1. Nous avons donc réitéré la validation croisée dans cet intervalle et obtenu $\lambda_{\text{opt}} = 0.02335461$.



Le modèle réalisé avec ce λ_{opt} présente un R^2 égal à 0.400427 et un MSE égal à 0.1491432. Ce modèle explique donc moins de variance que la régression PLS. Examinons maintenant l'évolution des coefficients de notre nouveau modèle :

Chemin de Régularisation de la Régression Ridge - Top 5 Variables



Les variables présentées ici sont celles qui exercent le plus d'influence, c'est-à-dire celles associées aux coefficients ayant les plus grandes valeurs absolues. On remarque, beaucoup de coefficients sont proches de 0, tandis que d'autres semblent être plus essentiels. Les coefficients qui ressortent le plus sont ceux liés à la photosynthèse, car ce sont eux qui contribuent le plus à la régression.

Variable	Coefficient
Intercept	4.9086
altitude	0.0004
pluvio_yr	-0.0015
pluvio_3	0.0066
lat	0.0348
pluvio_8	0.0029
altitude_Sol2	0.0002
evi_1	-3.2527
evi_6	3.0686
evi_10	0.7593

Table 15: Exemple de coefficients de 10 variables sélectionnées

L'analyse de ce tableau nous permet de confirmer que les variables liées à la photosynthèse sont associées aux plus grand coefficient en valeur absolue

Maintenant passons à l'aperçu de quelques variables

5.2 Régression LASSO


La mise en œuvre de la méthode LASSO fera l'objet de cette partie. Cette méthode consiste à minimiser l'erreur quadratique moyenne $\sum_{i=1}^n (y_i - x_i\beta)^2$ (OLS) sous la contrainte $\sum_{j=1}^p |\beta_j| \leq \gamma$. Cela revient à minimiser

$$\sum_{i=1}^n \left((y_i - x_i\beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right)$$

pour un certain λ qui dépend de γ , où λ est appelé le multiplicateur de Lagrange. L'estimateur lasso est défini par :

$$\hat{\beta}^L \in \arg \min \left(\sum_{i=1}^n (y_i - x_i\beta)^2 + \lambda \sum_{j=1}^p |\beta_j| \right)$$


De la même manière que pour la régression Ridge, nous avons réalisé la validation croisée à 10 ensembles pour déterminer le paramètre de régularisation optimal. Nous avons alors trouvé $\lambda_{\text{opt}} = 0.000380622$.



Le modèle réalisé avec ce λ_{opt} nous donne un R^2 égal à 0.482869 (ce modèle explique donc presque la moitié de la variance présente dans les données) et un MSE égal à 0.1399783.

Examinons maintenant l'évolution des coefficients de notre nouveau modèle :

Chemin de Régularisation de la Régression Lasso - Top 10 Variables



De même que pour la régression Ridge, on retrouve les variables en lien avec la photosynthèse comme variables les plus contributives à la régression.

Variable	Coefficient
Intercept	11.6958
altitude	0.0008
pluvio_yr	-0.0027
pluvio_1	0
pluvio_3	0.0037
pluvio_4	0
pluvio_6	0.0048
pluvio_12	-0.0023
lat	0
evi_1	-1.8386

Table 16: Extrait des coefficients de lasso

6. Synthèse & conclusions

La RMSE (Root Mean Square Error) est une métrique couramment utilisée pour évaluer la précision des modèles de régression. Mathématiquement, elle est définie comme la racine carrée de la moyenne des erreurs quadratiques entre les valeurs prédites et les valeurs réelles:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Variables/Méthodes	RCP par thèmes	RCP sur 6 CP
lat	0.271918871	0.2894
lon	0.191598078	0.2302
altitude	0.060516037	0.0156
pluvio_yr	0.004561298	-0.1082
pluvio_1	-0.231250774	-0.2468
pluvio_2	-0.233065744	-0.2176
pluvio_3	-0.161721658	-0.1648
pluvio_4	-0.2243653476	-0.2877
pluvio_5	-0.066285905	-0.1032
pluvio_6	0.239867877	0.2415
pluvio_7	0.311563440	0.3223
pluvio_8	0.315016922	0.3240
pluvio_9	0.128831922	0.0868
pluvio_10	-0.019499528	-0.0931
pluvio_11	-0.309578527	-0.351
pluvio_12	-0.232916509	-0.24
lat_Sol1	0.0504275821	0.049
lat_Sol2	0.014065553	0.0339
lat_Sol3	0.150607147	0.1253
lat_Sol5	-0.0223224266	0.0029
lat_Sol6	0.096561179	0.112
lon_Sol1	0.023812303	0.0214
lon_Sol2	0.001547408	0.0186

lon_Sol3	0.055351931	0.0439
lon_Sol4	-0.025367128	-0.0031
lon_Sol5	0.014982918	0.008
pluvio_5_Sol6	-0.035105944	-0.0339
pluvio_5_Sol6	-0.008986440	-0.0073
pluvio_6_Sol1	0.026906323	0.0238
evi_13	0.253549498	0.2491
evi_14	0.204024412	0.2271
evi_15	0.157131649	0.1673
evi_16	0.143299457	0.1254
evi_17	0.068205741	0.043
evi_18	0.028315561	-0.0059
evi_19	-0.007663028	-0.0148
evi_20	-0.009227930	-0.0171
evi_21	-0.091620017	-0.0974
evi_22	-0.167735054	-0.1832
evi_23	-0.182380400	-0.2108

Table des coefficients de X pour chaque méthode

Les variables qui ont des coefficients positifs augmentent la densité du peuplement arboré. Par exemple, une augmentation d'une unité dans la variable lat est associée à une augmentation de la densité du peuplement arboré, tout comme lon et altitude.

Les variables avec des coefficients négatifs (le reste) ont un effet négatif sur la densité du peuplement arboré.

Par exemple, une augmentation d'une unité dans la variable pluvio_yr ou pluvio_1 est associée à une diminution de la densité du peuplement arboré.

La régression LASSO a un pouvoir de sélection de variables en rendant certains coefficients nuls. Les coefficients obtenus avec la régression LASSO sont de même signe que ceux obtenus par la régression Ridge, mais sont plus grands en valeur absolue.

En se basant sur le RMSE (l'erreur quadratique moyenne) que les modèles ont fait sur l'échantillon de test, on peut dire que le modèle Lasso est meilleur que les autres même son R² est le plus élevé.

Nous avons essayer d'améliorer notre modèle en utilisant la régression élastique, qui combine les pénalités Lasso (L1) et Ridge (L2) pour créer une méthode de régression plus flexible, capable de gérer des données avec des variables corrélées. Nous observons un R² de 0.4926, qui a légèrement augmenté par rapport aux autres modèles. Cependant, le modèle devient plus complexe que le Lasso, qui élimine certaines variables.

Annexe

```

1 ##### Packages nécessaires
2
3 # Charger les bibliothèques essentielles pour réaliser l'ACP, manipuler les données, et cr
4 library(FactoMineR)      # Outils pour l'Analyse en Composantes Principales (ACP)
5 library(factoextra)      # Visualisation des résultats de l'ACP
6 library(ggplot2)         # Création de graphiques variés
7 library(ade4)            # Analyses spécifiques pour les données écologiques

```

```

8 library(dplyr)           # Manipulation et traitement des données
9 library(reshape2)       # Restructuration des données, souvent utilisé pour les tables piv
10 library(pheatmap)      # Création de cartes de chaleur
11 library(RColorBrewer)   # Palette de couleurs personnalisées
12 library(tidyr)         # Fonctionnalités supplémentaires de manipulation de données
13 library(glmnet)        # Modélisation de régression pénalisée (Lasso et Ridge)
14 library(corrplot)      # Visualisation des matrices de corrélation
15
16 ##### Question 0 - Préparation des données
17
18 # Lire le fichier "Datagenus.csv" en prenant la première colonne comme identifiant de ligne
19 data <- read.csv("Datagenus.csv", header = TRUE, sep = "\t", dec = ".", row.names = 1)
20 # Supprimer les colonnes "forest" (colonne 30) et les colonnes 69 à 108 pour simplifier le
21 data <- data[, -30]
22 data <- data[, -c(69:108)]
23 ##### Question 1 - Calculs de variables
24 #####1a) Calcul de la densité notée Y
25 # Calculer la densité en sommant les 27 premières colonnes (Gen1 à Gen7) pour chaque ligne
26 Y <- rowSums(data[, 1:27])
27 # Normaliser la densité Y par la surface de chaque observation pour obtenir une densité mo
28 Y <- Y / data$surface
29 # Ajouter Y comme colonne dans le jeu de données principal.
30 data <- cbind(data, Y)
31
32 #####1b) Calcul des variables explicatives Codage en indicatrices pour
33 # Extraire les variables géographiques quantitatives et les variables EVI (Enhanced Vegeta
34 geographi_quant <- data[c(28:41, 66, 67)]
35 Evi <- data[, 43:65]
36 # Extraire la variable qualitative "geology" pour les analyses suivantes.
37 geology <- data$geology
38
39
40
41 # Transformer "geology" en variables indicatrices pour représenter chaque type de sol par
42 geology <- acm.disjonctif(as.data.frame(geology))
43 colnames(geology) <- c("Sol1", "Sol2", "Sol3", "Sol5", "Sol6")
44
45 # Initialiser une liste pour stocker les produits d'interaction entre chaque paire (géograph
46 produits <- list()
47
48 # Boucle pour calculer et nommer les interactions.
49 for (i in 1:ncol(geographi_quant)) {
50   for (j in 1:ncol(geology)) {
51     interaction_col <- geographi_quant[, i] * geology[, j]
52     col_name <- paste0(colnames(geographi_quant)[i], "_", colnames(geology)[j])
53     produits[[col_name]] <- interaction_col
54   }
55 }
56 # Convertir la liste d'interactions en un data frame pour faciliter les analyses ultérieures
57 produits_df <- as.data.frame(produits)
58

```

```

59 #####Vérification de la Multicolinéarité des Variables
60
61 # Combiner toutes les variables explicatives dans un seul data frame pour l'analyse de cor
62 variables_explicatives <- cbind(geographi_quant, produits_df, geology, Evi)
63
64 # Calculer la matrice de corrélation des variables explicatives pour détecter des corrélats
65 M <- cor(variables_explicatives, use = "complete.obs")
66
67 # Affichage de la matrice de corrélation avec corrplot, pour visualiser les relations entre
68 corrplot(M, method = "circle", type = "full", is.corr = TRUE, na.label = "_",
69         tl.cex = 0.8, tl.col = "black", tl.srt = 90, addgrid.col = "gray")
70
71 ##### Question 2 Analyse en Composantes Prin
72
73 # Réalisation de l'ACP sur les variables explicatives et visualisation des inerties.
74 resultats_acp <- PCA(variables_explicatives, ncp = 10, graph = FALSE)
75 fviz_eig(resultats_acp, addlabels = TRUE, ylim = c(0, 25), ncp = 10) +
76   ggtitle("Inertie_fournie_par_chaque_axe_en_pourcentage") +
77   theme_minimal() +
78   theme(plot.title = element_text(hjust = 0.5, size = 14, face = "bold"))
79 ##### ACP directe en fonction de la modalité de type de sol
80
81 # Conversion de 'geology' en facteur pour distinguer les types de sol dans l'ACP.
82 geology_factor <- as.factor(apply(geology, 1, function(x) {
83   paste(names(x)[x == 1], collapse = "_")
84 })))
85
86 # Afficher les individus avec une couleur par type de sol, uniquement avec des points.
87 fviz_pca_ind(resultats_acp,
88             geom.ind = "point", col.ind = geology_factor, pointshape = 16, pointsize = 3,
89             ggtitle("Plan_direct_(1,2)") +
90             theme_minimal() +
91             theme(axis.text = element_text(size = 10, face = "bold"), axis.title = element_text(size = 12, face = "bold"),
92                   legend.position = "right", legend.title = element_text(size = 12, face = "bold"),
93                   plot.title = element_text(size = 17, face = "bold")) +
94             labs(col = "Type_de_Sol"))
95
96 ##### ACP en fonction des contributions
97
98 # Calculer et normaliser les contributions des individus.
99 contributions <- resultats_acp$ind$coord^2
100 contrib_relative <- rowSums(contributions) / sum(contributions)
101 contrib_normalized <- (contrib_relative - min(contrib_relative)) / (max(contrib_relative) - min(contrib_relative))
102
103 # Visualiser les individus en fonction de leur contribution normalisée.
104 fviz_pca_ind(resultats_acp,
105             geom.ind = "point", col.ind = contrib_normalized, pointshape = 16, pointsize = 3,
106             ggtitle("Plan_direct_(1,2)_des_individus_et_leurs_Contributions") +
107             theme_minimal() +
108             theme(axis.text = element_text(size = 10, face = "bold"), axis.title = element_text(size = 12, face = "bold"),
109                   legend.position = "right", legend.title = element_text(size = 12, face = "bold"),

```

```

110     plot.title = element_text(size = 18, face = "bold")) +
111     labs(col = "Contributions") +
112     scale_color_gradientn(colors = c("gold", "blue", "red"), values = scales::rescale(c(0, 0.5, 1)))
113
114
115 ##### ACP duale pour les variables bien représentées
116 # Visualisation des variables en fonction du cos2.
117 fviz_pca_var(resultats_acp, col.var = "cos2", gradient.cols = c("blue", "#E7B800", "#FC4E00"),
118             repel = FALSE, pointsize = 4, labelsize = 0, alpha.var = 8) +
119     ggtitle("Plan Dual(1,2)") +
120     theme_minimal() +
121     theme(plot.title = element_text(size = 16, face = "bold", hjust = 0.5), axis.text = element_text(size = 12),
122           axis.title = element_text(size = 14, face = "bold"), legend.text = element_text(size = 12))
123 ##### Graphique de Y et de Y_hat pour les 6 composantes significatives
124
125 predictions <- predict(modele_regression1)
126
127 # Créer un DataFrame pour ggplot
128 data_plot <- data.frame(
129     Observed = data_regression1$target_variable,
130     Predicted = predictions
131 )
132
133 # Construire le graphique avec ggplot2
134 ggplot(data_plot, aes(x = Observed, y = Predicted)) +
135     geom_point(color = "blue", size = 1) + # Points de dispersion
136     geom_abline(color = "red", linetype = "solid") + # Ligne pleine
137     labs(
138         title = "Graphique des Valeurs Observées vs Prédites",
139         x = "Valeurs Observées (Y)",
140         y = "Valeurs Prédites  $\hat{Y}$ "
141     ) +
142     scale_x_continuous(limits = c(0, 60)) +
143     scale_y_continuous(limits = c(0, 60)) +
144     theme_minimal() +
145     theme(
146         plot.title = element_text(size = 15, face = "bold"),
147         axis.title = element_text(size = 14),
148         axis.text = element_text(size = 12)
149     )
150
151 ##### Correction de la linéarité avec la log
152
153 # Transformation logarithmique de Y
154 epsilon <- 1
155 data_regression_log <- data.frame(composantes1, log_target = log(data$Y + epsilon))
156 data_regression1$log_target <- log(data_regression1$target_variable + epsilon)
157
158 # Ajustement du modèle avec la variable transformée
159 modele_log <- lm(log_target ~ ., data = data_regression_log)
160

```

```

161 # Résumé du modèle
162 summary(modele_log)
163
164 predictions <- predict(modele_log)
165
166 # Créer un DataFrame pour ggplot
167 data_plot <- data.frame(
168   Observed = data_regression1$log_target,
169   Predicted = predictions
170 )
171
172 # Construire le graphique avec ggplot2
173 ggplot(data_plot, aes(x = Observed, y = Predicted)) +
174   geom_point(color = "blue", size = 1) +
175   geom_abline(color = "red", linetype = "solid") +
176   labs(
177     title = "Graphique des Valeurs Observées vs Prédites avec le modele_log",
178     x = "Valeurs Observées (log(Y+1))",
179     y = "Valeurs Prédites  $\hat{Y}$ ()"
180   ) +
181   scale_x_continuous(limits = c(0, 5)) +
182   scale_y_continuous(limits = c(0, 5)) +
183   theme_minimal() +
184   theme(
185     plot.title = element_text(size = 15, face = "bold"),
186     axis.title = element_text(size = 14),
187     axis.text = element_text(size = 12)
188   )
189
190 ##### QQ_plot
191 residuals <- residuals(modele_log)
192
193 # Créer un DataFrame pour le graphique Q-Q
194 df_residuals <- data.frame(residuals = residuals)
195
196 # Générer le graphique Q-Q avec ggplot2
197 qq_plot <- ggplot(df_residuals, aes(sample = residuals)) +
198   stat_qq(size = 2, color = "blue") +
199   stat_qq_line(color = "darkred", linetype = "dashed") +
200   ggtitle("Q-Q Plot des Résidus") +
201   xlab("Quantiles Théoriques") +
202   ylab("Quantiles des Résidus") +
203   theme_minimal() +
204   theme(
205     plot.title = element_text(size = 18, face = "bold"),
206     axis.title = element_text(size = 14),
207     axis.text = element_text(size = 12)
208   )
209
210 print(qq_plot)
211

```

```

212 ##### ACP par thème
213
214 ##### Thème photosynthèse
215
216 # Effectuer l'ACP avec les variables photosynthèse
217 resultats_acp_photosynthese <- PCA(Evi, ncp = 10, graph = FALSE)
218
219 # Visualiser les inerties
220 fviz_eig(resultats_acp_photosynthese, addlabels = TRUE, ylim = c(0, 50), ncp = 10) +
221   ggtitle("Inertie_fournie_par_chaque_axe_en_pourcentage_ACP_photosynthèse") +
222   theme_minimal() +
223   theme(
224     plot.title = element_text(hjust = 0.5, size = 14, face = "bold")
225   )
226
227 # Afficher le tableau des valeurs propres
228 valeurs_propres1 <- resultats_acp_photosynthese$eig
229 valeurs_propres1[1:10,]
230
231 ##### ACP duale des variables bien représentées
232
233 fviz_pca_var(resultats_acp_photosynthese,
234   col.var = "cos2",
235   select.var = list(cos2 = 0.7),
236   gradient.cols = c("blue", "#E7B800", "#FC4E07", "orange"),
237   repel = TRUE,
238   pointsize = 4,
239   labelsize = 2,
240   alpha.var = 10
241 ) +
242   ggtitle("Plan_ACP_Direct_et_Dual_(1,2)_de_photosynthèse_avec_Filtre_Cos²_0,7") +
243   theme_minimal() +
244   theme(
245     plot.title = element_text(size = 12, face = "bold"),
246     axis.text = element_text(size = 12, face = "bold"),
247     axis.title = element_text(size = 14, face = "bold"),
248     legend.text = element_text(size = 12),
249     legend.title = element_text(size = 13)
250   )
251
252 ##### Heatmap de corrélations
253
254 # Calculer la matrice de corrélation
255 correlation_matrix <- cor(Evi)
256
257 # Transformer la matrice de corrélation en format long pour ggplot2
258 correlation_data <- melt(correlation_matrix)
259
260 # Créer la heatmap
261 ggplot(correlation_data, aes(Var1, Var2, fill = value)) +
262   geom_tile(color = "white") +

```

```

263 scale_fill_gradient2(low = "blue", mid = "white", high = "red",
264                       midpoint = 0, limit = c(-1, 1),
265                       space = "Lab", name = "Corrélation") +
266 theme_minimal() +
267 theme(
268   axis.text.x = element_text(angle = 45, vjust = 1, hjust = 1),
269   axis.title = element_blank(),
270   plot.title = element_text(hjust = 0.5, size = 15, face = "bold")
271 ) +
272 ggtitle("Heatmap de la matrice de corrélation de Evi") +
273 coord_fixed()
274
275 ##### Thème géographique
276
277 geo_interactions <- cbind(geographi_quant, produits_df, geology)
278 resultats_acp_geo_interactions <- PCA(geo_interactions, ncp = 20, graph = FALSE)
279
280 fviz_eig(resultats_acp_geo_interactions, addlabels = TRUE, ylim = c(0, 30), ncp = 10) +
281   ggtitle("Inertie fournie par chaque axe en pourcentage ACP (géographique)") +
282   theme_minimal() +
283   theme(
284     plot.title = element_text(hjust = 0.5, size = 14, face = "bold")
285   )
286
287 # Afficher le tableau des valeurs propres
288 valeurs_propres2 <- resultats_acp_geo_interactions$eig
289 valeurs_propres2[1:10,]
290
291 ##### ACP duale
292
293 fviz_pca_var(resultats_acp_geo_interactions,
294             col.var = "cos2",
295             select.var = list(cos2 = 0.7),
296             gradient.cols = c("blue", "#E7B800", "#FC4E07", "orange"),
297             repel = TRUE,
298             pointsize = 4,
299             labelsize = 2,
300             alpha.var = 10
301 ) + theme_minimal() +
302 ggtitle("Plan ACP Dual (1,2) de géographie avec Filtre Cos² 0,7") +
303 theme(
304   plot.title = element_text(size = 12, face = "bold"),
305   axis.text = element_text(size = 12, face = "bold"),
306   axis.title = element_text(size = 14, face = "bold"),
307   legend.text = element_text(size = 12),
308   legend.title = element_text(size = 13)
309 )
310
311 ##### Régression sur l'union
312
313 composantes_P <- resultats_acp_photosynthese$ind$coord[, 1:3]

```

```

314 composantes_G_I <- resultats_acp_geo_interactions$ind$coord[, 1:6]
315 union <- cbind(composantes_P, composantes_G_I)
316 data_regression_union <- data.frame(union, target_variable = data$Y)
317
318 # Construire le modèle de régression
319 modele_regression_union <- lm(target_variable ~ ., data = data_regression_union)
320
321 # Résumé du modèle
322 summary(modele_regression_union)
323 ##### Modèle avec les variables significatives
324 composantes_P1 <- resultats_acp_photosynthese$ind$coord[, 2]
325 composantes_G_I1 <- resultats_acp_geo_interactions$ind$coord[, c(1, 2, 3, 5)]
326 union1 <- cbind(composantes_P1, composantes_G_I1)
327 data_regression_union1 <- data.frame(union1, target_variable = data$Y)
328
329 summary(modele_regression_union1)
330
331 ##### Évaluer le modèle
332 predictions_union <- predict(modele_regression_union1)
333
334 # Créer un DataFrame pour ggplot
335 data_plot_union <- data.frame(
336   Observed = data_regression_union1$target_variable,
337   Predicted = predictions_union
338 )
339
340 # Graphique avec ggplot2
341 ggplot(data_plot_union, aes(x = Observed, y = Predicted)) +
342   geom_point(color = "blue", size = 1) + # Points de dispersion
343   geom_abline(color = "red", linetype = "solid") + # Ligne de référence
344   labs(
345     title = "Valeurs Observées vs Prédites avec l'union",
346     x = "Valeurs Observées (Y)",
347     y = "Valeurs Prédites  $\hat{Y}()$ "
348   ) +
349   scale_x_continuous(limits = c(0, 60)) + # Échelle x
350   scale_y_continuous(limits = c(0, 60)) + # Échelle y
351   theme_minimal() +
352   theme(
353     plot.title = element_text(size = 14, face = "bold"),
354     axis.title = element_text(size = 14),
355     axis.text = element_text(size = 12)
356   )
357
358 ##### Corriger la linéarité avec log
359 data_regression_union_log <- data.frame(union1, log_target = log(data$Y + 1))
360
361 # Construire le modèle de régression log
362 modele_regression_union_log <- lm(log_target ~ ., data = data_regression_union_log)
363 summary(modele_regression_union_log)
364

```



```

365 #####Évaluer le modèle log
366 predictions_union_log <- predict(modele_regression_union_log)
367 data_plot_union_log <- data.frame(
368   Observed = data_regression_union_log$log_target,
369   Predicted = predictions_union_log
370 )
371 ggplot(data_plot_union_log, aes(x = Observed, y = Predicted)) +
372   geom_point(color = "blue", size = 1) +           # Points de dispersion
373   geom_abline(color = "red", linetype = "solid") + # Ligne de référence
374   labs(
375     title = "Valeurs_Observées_vs_Prédites_avec_l'union_du_modèle_log",
376     x = "Valeurs_Observées(Y)",
377     y = "Valeurs_Prédites_Ŷ()"
378   ) +
379   scale_x_continuous(limits = c(0, 5)) +           # Échelle x log
380   scale_y_continuous(limits = c(0, 5)) +           # Échelle y log
381   theme_minimal() +
382   theme(
383     plot.title = element_text(size = 12, face = "bold"),
384     axis.title = element_text(size = 14),
385     axis.text = element_text(size = 12)
386   )
387
388 ##### 4 Regression sur les composantes PLS

```

Code R